Informatica e Computazione
Interprete per Linguaggio LISP-like

Armando Tacchella

Corso di Laurea in Ingegneria Informatica
Dipartimento di Informatica, Bioingegneria, Robotica e Ingegneria dei Sistemi

Sommario

1. Introduzione
2. Formato di input
3. Semantica
4. Suggerimenti per il progetto e l'implementazione
5. Altre specifiche di progetto

Compilatori e interpreti: cosa?

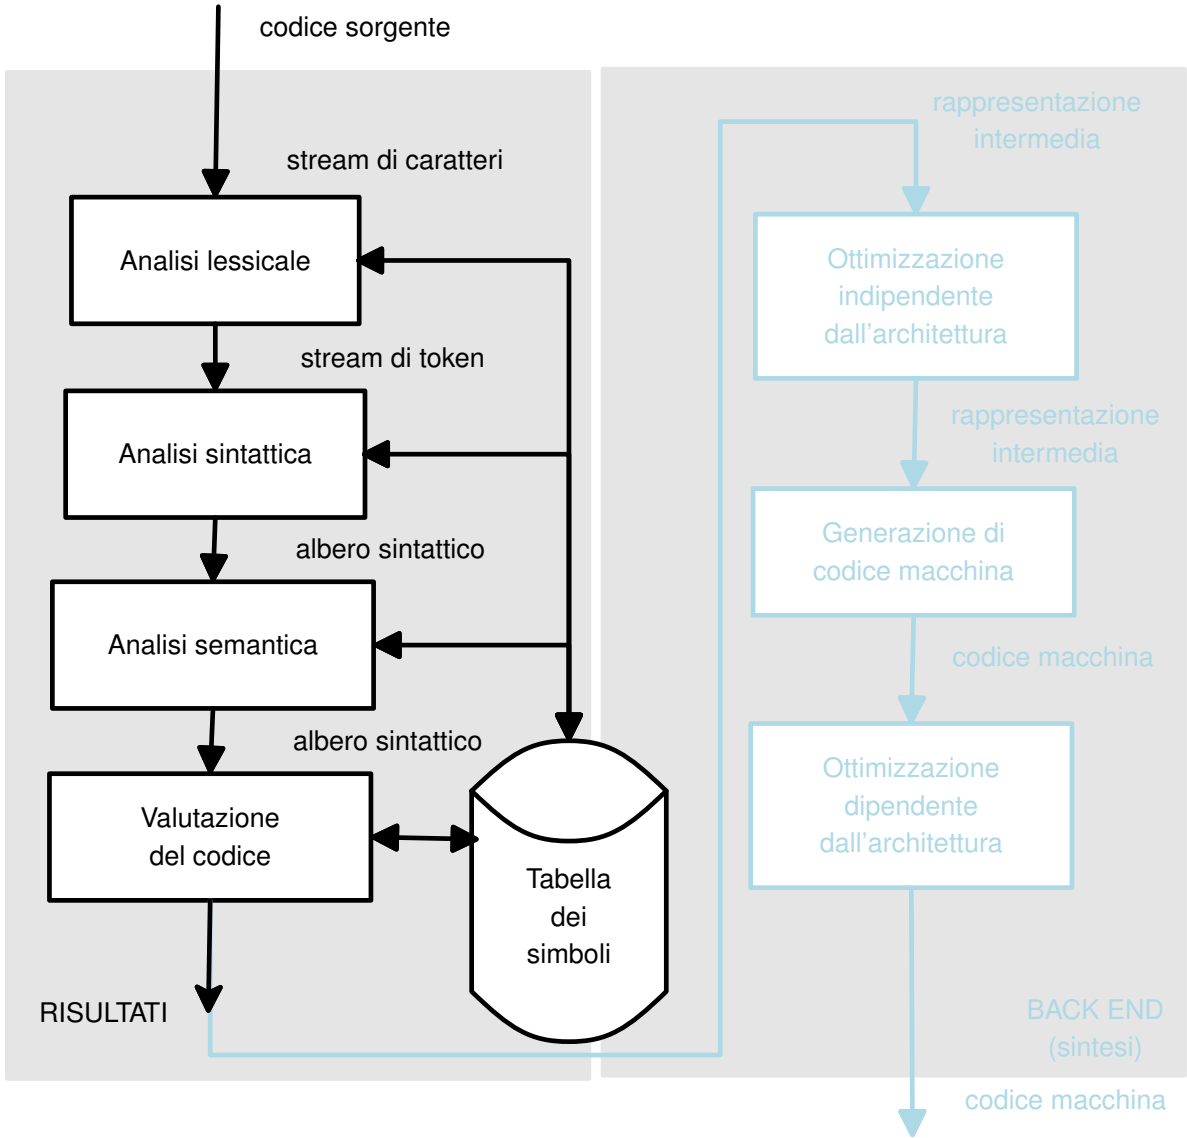

Interprete di un linguaggio LISP-like: perché?

- Un compito **semplice**:
  - solo costrutti elementari: I/O, variabili, espressioni, scelte condizionali e cicli;
  - soltanto due tipi di dato: interi e booleani
  - nessuna gestione di tipi aggiuntivi, funzioni, classi, ...
  - nessuna gestione di ambiti, visibilità, ...
- Parti costituenti di **tutti** i compilatori ed interpreti per utilizzo professionale

[A. V. Aho, M. Lam, R. Sethi, J.D. Ullman. Compilers - Principles, Techniques and Tools. Addison-Wesley, 2nd edition, 2006]

Interpretazione di espressioni: come?

- Specifica del linguaggio in input e del formato di output
  - **Grammatica libera dal contesto** per l'input
  - **Descrizione informale** dei risultati attesi per l'output
  - **Vettori di test** per verificare la soluzione
- Due approcci possibili:
  - Approccio **automatizzato**: scrittura della grammatica di input e delle regole di interpretazione nel formato di un generatore di traduttori (ad esempio, ANTLR)
  - Approccio **manuale**: sviluppo e implementazione degli algoritmi a partire dalle specifiche
- Per l'esercitazione è prevista la soluzione manuale.

Per approfondimenti sulla generazione automatica: `www.antrl.org`

Notazione di base

Data una grammatica libera dal contesto $G = (V_N, V_T, P, S)$

- la produzione $A \rightarrow \alpha \mid \beta$ **abbrevia** le produzioni

$$A \rightarrow \alpha$$
$$A \rightarrow \beta$$

- i **caratteri corsivi** definiscono i simboli **non terminali** V_N, ad esempio *program*, *statement*, ecc.
- i **caratteri standard** sono riservati ai simboli **terminali** V_T, ad esempio SET, MUL, (,), ecc.
- Come consueto, il simbolo ϵ denota la stringa vuota.

Grammatica di input (1)

$$
\begin{aligned}
\textit{program} &\rightarrow \textit{stmt\_block} \\
\textit{stmt\_block} &\rightarrow \textit{statement} \mid (\ \text{BLOCK}\ \textit{statement\_list}\ ) \\
\textit{statement\_list} &\rightarrow \textit{statement}\ \textit{statement\_list} \mid \textit{statement}
\end{aligned}
$$

$$
\begin{aligned}
\textit{statement} \rightarrow\ & \textit{variable\_def} \mid \\
& \textit{io\_stmt} \mid \\
& \textit{cond\_stmt} \mid \\
& \textit{loop\_stmt}
\end{aligned}
$$

$$
\begin{aligned}
\textit{variable\_def} &\rightarrow (\ \text{SET}\ \textit{variable\_id}\ \textit{num\_expr}\ ) \\
\textit{io\_stmt} &\rightarrow (\ \text{PRINT}\ \textit{num\_expr}\ ) \mid (\ \text{INPUT}\ \textit{variable\_id}\ ) \\
\textit{cond\_stmt} &\rightarrow (\ \text{IF}\ \textit{bool\_expr}\ \textit{stmt\_block}\ \textit{stmt\_block}\ ) \\
\textit{loop\_stmt} &\rightarrow (\ \text{WHILE}\ \textit{bool\_expr}\ \textit{stmt\_block}\ )
\end{aligned}
$$

Grammatica di input (2)

num_expr → (ADD *num_expr num_expr*)
| (SUB *num_expr num_expr*)
| (MUL *num_expr num_expr*)
| (DIV *num_expr num_expr*)
| *number*
| *variable_id*

bool_expr | (LT *num_expr num_expr*)
| (GT *num_expr num_expr*)
| (EQ *num_expr num_expr*)
| (AND *bool_expr bool_expr*)
| (OR *bool_expr bool_expr*)
| (NOT *bool_expr*)
| TRUE | FALSE

Grammatica di input (3)

$$
\begin{aligned}
\textit{variable\_id} &\rightarrow \textit{alpha\_list} \\
\textit{alpha\_list} &\rightarrow \textit{alpha}\ \textit{alpha\_list} \mid \textit{alpha} \\
\textit{alpha} &\rightarrow \text{a} \mid \text{b} \mid \text{c} \mid \ldots \mid \text{z} \mid \text{A} \mid \text{B} \mid \text{C} \mid \ldots \mid \text{Z}
\end{aligned}
$$

$$
\begin{aligned}
\textit{number} &\rightarrow \text{-}\ \textit{posnumber} \mid \textit{posnumber} \\
\textit{posnumber} &\rightarrow 0 \mid \textit{sigdigit}\ \textit{rest} \\
\textit{sigdigit} &\rightarrow 1 \mid \ldots \mid 9 \\
\textit{rest} &\rightarrow \textit{digit}\ \textit{rest} \mid \epsilon \\
\textit{digit} &\rightarrow 0 \mid \textit{sigdigit}
\end{aligned}
$$

- La grammatica proposta è **non ambigua**
- **Al più** due simboli non terminali disambiguano qualsiasi produzione:
  - “(SET”, “(PRINT”, “(INPUT”, ecc. consentono di risolvere l’ambiguità tra le varie istruzioni
  - “(ADD”, “(SUB”, ecc., consentono di risolvere l’ambiguità tra i vari tipi di espressione

Esempio di file di input: calcolo del fattoriale

```
(BLOCK
  (INPUT n)
  (SET result 1)
  (WHILE (GT n 0)
    (BLOCK
      (SET result (MUL result n))
      (SET n (SUB n 1)))
  )
  (PRINT result))
```

- Spazi, tabulazioni e righe vuote **non fanno parte** della sintassi del programma
- Devono essere considerati come “spazio vuoto” e **ignorati**.
- Le **parole chiave** in questo programma sono BLOCK, INPUT, SET, WHILE, GT, MUL, SUB e PRINT

Interpretazione delle dichiarazioni di variabili

Il risultato corrispondente ad una istruzione

(SET *variable_id num_expr*)

deve essere:

- la **creazione** della variable *variable_id*, se non era stata già definita in precedenza, e
- l'**assegnazione** alla variable *variable_id* del **valore** dell'espressione *num_expr*.

Possono verificarsi i seguenti errori:

- la dichiarazione non è sintatticamente corretta,
- *variable_id* è una parola chiave, oppure
- *num_expr* non è sintatticamente corretta, oppure contiene un errore semantico (ad e.s., divisione per zero).

Interpretazione dello statement di input

Il risultato corrispondente ad una istruzione

(INPUT *variable_id*)

deve essere:

- la **creazione** della variable *variable_id*, se non era stata già definita in precedenza, e
- l'**assegnazione** alla variable *variable_id* del valore **letto da console**.

Possono verificarsi i seguenti errori:

- l'istruzione non è sintatticamente corretta,
- *variable_id* è una parola chiave, oppure
- viene inserito da console un valore illecito (sono consentiti **solo** numeri interi positivi e negativi).

Interpretazione dello statement di output

Il risultato corrispondente ad una istruzione

(PRINT *num_expr*)

deve essere la **visualizzazione in console** del **valore** dell'espressione *num_expr*.

Possono verificarsi i seguenti errori:

- l'istruzione non è sintatticamente corretta,
- *num_expr* non è sintatticamente corretta, oppure contiene variabili non definite in precedenza con SET o INPUT, oppure contiene un errore semantico (ad e.s., divisione per zero).

Interpretazione dell'istruzione di scelta condizionata

Il risultato corrispondente ad una istruzione

$$(\text{IF } \textit{bool\_expr}\ \textit{stmt\_block}_1\ \textit{stmt\_block}_2)$$

deve essere:

- l'esecuzione di $\textit{stmt\_block}_1$ nel caso in cui *bool_expr* valuti a vero, oppure
- l'esecuzione di $\textit{stmt\_block}_2$ nel caso in cui *bool_expr* valuti a falso.

Possono verificarsi i seguenti errori:

- la dichiarazione non è sintatticamente corretta,
- *bool_expr* non è sintatticamente corretta o contiene variabili non definite in precedenza, oppure
- uno dei due *stmt_block* non è sintatticamente corretto, oppure, se eseguito, contiene un errore semantico (ad e.s., divisione per zero).

Interpretazione dell'istruzione di iterazione

Il risultato corrispondente ad una istruzione

(WHILE *bool_expr stmt_block*)

deve essere l'esecuzione di *stmt_block* fintanto che l'espressione *bool_expr* valuta a vero; l'esecuzione non avviene se *bool_expr* è falsa in partenza.

Possono verificarsi i seguenti errori:

- la dichiarazione non è sintatticamente corretta,
- *bool_expr* non è sintatticamente corretta o contiene variabili non definite in precedenza, oppure
- lo *stmt_block* non è sintatticamente corretto, oppure, se eseguito, contiene un errore semantico (ad e.s., divisione per zero).

Interpretazione di un blocco di istruzioni

Il risultato corrispondente ad una istruzione

$$(\text{BLOCK } \mathit{statement}_1 \ \ldots \mathit{statement}_n)$$

deve essere l'esecuzione **in sequenza** dei diversi statement.

Possono verificarsi i seguenti errori:

- la dichiarazione non è sintatticamente corretta,
- per qualche i, $\mathit{statment}_i$ non è sintatticamente corretto, contiene variabili non definite in precedenza, oppure contiene un errore semantico (ad e.s., divisione per zero).

Interpretazione di espressioni

- Le espressioni numeriche vengono interpretate con l'ovvia semantica per valori ed operatori: somma per ADD, sottrazione per SUB, ecc.
- Nelle espressioni booleane, gli operatori relazionali hanno la seguente semantica:
  - GT sta per "greater than", quindi (GT *a b*) è vero se il valore di *a* è strettamente maggiore di quello di *b*;
  - Analogamente LT sta per "lesser than" e EQ sta per "equal" con il relativo significato inteso.
- Gli operatori booleani AND, OR, NOT hanno anch'essi l'ovvia semantica; AND e OR sono **cortocircuitati**, ossia
  - (*a* AND *b*) nel caso in cui *a* valuti a falso è immediatamente valutata a falso (*b* non viene valutato);
  - (*a* OR *b*) nel caso in cui *a* valuti a vero è immediatamente valutata a vero (*b* non viene valutato).

Osservazioni aggiuntive

- La grammatica **non permette** la definizione di variabili che non siano di tipo numerico: SET richiede una *num_expr*.
- Nel caso di INPUT viene imposto il vincolo che il valore letto sia un intero.
- Esiste un unico ambito globale per le variabili.
- Le variabili sono definite dinamicamente (non è necessario dichiararle prima di utilizzarle per la prima volta come in C/C++/Java).

Esempio di esecuzione

Ad esempio, in corrispondenza del programma visto prima, l'interazione con l'utente sarebbe il seguente:

```
> 5
120
```

Nota: Come ulteriore semplificazione, si assuma che gli interi forniti in ingresso siano sempre rappresentabili in registri a 64 bit (gli `int64_t` del C++), ossia per qualsiasi numero n utilizzato si ha che $-2^{63} \leq n < 2^{63}$.

Nota: Non è necessario gestire condizioni di overflow o underflow nelle operazioni aritmetiche, mentre è necessario gestire la divisione per zero.

Architettura funzionale

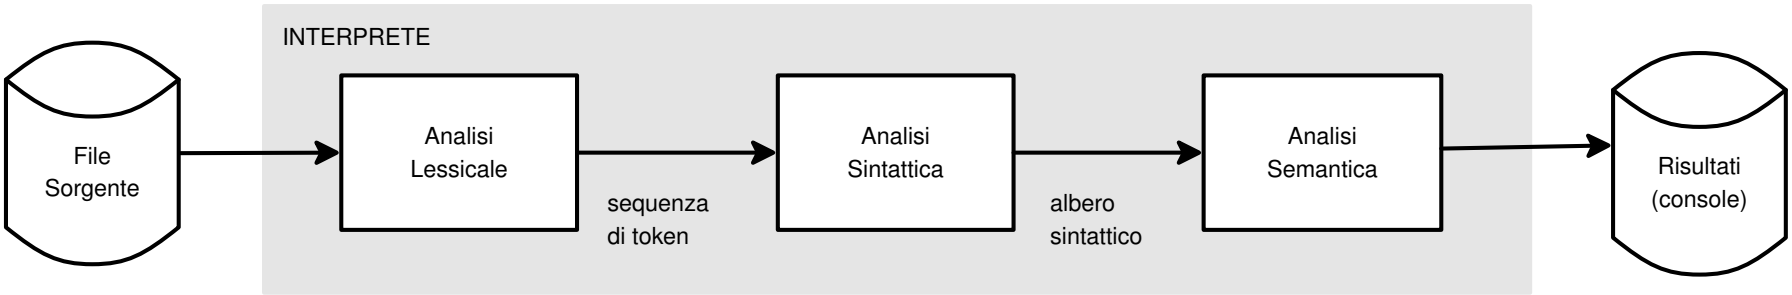

Analisi lessicale (1)

- Lettura del sorgente fornendo in uscita la sequenza degli ***elementi lessicali*** (***parole*** o *token*) del programma.
- Formalmente, per la grammatica dei file sorgente, un elemento lessicale corrisponde ad uno dei seguenti **gruppi**:
  - una **parola chiave**: BLOCK, INPUT, PRINT, SET, WHILE, IF, GT, LT, EQ, AND, OR, NOT, TRUE, FALSE, ADD, SUB, MUL, DIV;
  - una **parentesi** aperta o chiusa;
  - un **numero** (definito con le regole *number*);
  - un **variabile** (definita con le regole *variable_id*);
- I token corrispondono ai **simboli terminali** di una versione "astratta" della grammatica che descrive le espressioni.

Grammatica astratta

L'utilizzo dei token corrisponde a utilizzare per l'analisi sintattica le seguenti regole (in grassetto i simboli terminali):

$$
\begin{aligned}
\textit{program} &\rightarrow \textit{stmt\_block} \\
\textit{stmt\_block} &\rightarrow \textit{statement} \mid \textbf{(}\ \textbf{BLOCK}\ \textit{statement\_list}\ \textbf{)} \\
\textit{statement\_list} &\rightarrow \textit{statement}\ \textit{statement\_list} \mid \textit{statement}
\end{aligned}
$$

$$
\begin{aligned}
\textit{statement} \rightarrow\ & \textit{variable\_def} \mid \\
& \textit{io\_stmt} \mid \\
& \textit{cond\_stmt} \mid \\
& \textit{loop\_stmt}
\end{aligned}
$$

$$
\begin{aligned}
\textit{variable\_def} &\rightarrow \textbf{(}\ \textbf{SET}\ \textit{variable\_id}\ \textit{num\_expr}\ \textbf{)} \\
\textit{io\_stmt} &\rightarrow \textbf{(}\ \textbf{PRINT}\ \textit{num\_expr}\ \textbf{)} \mid \textbf{(}\ \textbf{INPUT}\ \textit{variable\_id}\ \textbf{)} \\
\textit{cond\_stmt} &\rightarrow \textbf{(}\ \textbf{IF}\ \textit{bool\_expr}\ \textit{stmt\_block}\ \textit{stmt\_block}\ \ \textbf{)} \\
\textit{loop\_stmt} &\rightarrow \textbf{(}\ \textbf{WHILE}\ \textit{bool\_expr}\ \textit{stmt\_block}\ \textbf{)}
\end{aligned}
$$

Grammatica astratta (segue)

$$
\begin{aligned}
\textit{num\_expr} \rightarrow\ & \textbf{(ADD } \textit{num\_expr num\_expr } \textbf{)} \\
\mid\ & \textbf{(SUB } \textit{num\_expr num\_expr } \textbf{)} \\
\mid\ & \textbf{(MUL } \textit{num\_expr num\_expr } \textbf{)} \\
\mid\ & \textbf{(DIV } \textit{num\_expr num\_expr } \textbf{)} \\
\mid\ & \textbf{\textit{number}} \\
\mid\ & \textbf{\textit{variable\_id}}
\end{aligned}
$$

$$
\begin{aligned}
\textit{bool\_expr}\ \mid\ & \textbf{(LT } \textit{num\_expr num\_expr } \textbf{)} \\
\mid\ & \textbf{(GT } \textit{num\_expr num\_expr } \textbf{)} \\
\mid\ & \textbf{(EQ } \textit{num\_expr num\_expr } \textbf{)} \\
\mid\ & \textbf{(AND } \textit{bool\_expr bool\_expr } \textbf{)} \\
\mid\ & \textbf{(OR } \textit{bool\_expr bool\_expr } \textbf{)} \\
\mid\ & \textbf{(NOT } \textit{bool\_expr } \textbf{)} \\
\mid\ & \textbf{TRUE} \mid \textbf{FALSE}
\end{aligned}
$$

Analisi sintattica

- Legge la **sequenza di token** fornita dall'analizzatore lessicale e ne controlla la **correttezza sintattica**.
- Fornisce in uscita una descrizione sotto forma di albero del programma in ingresso (c.d. **albero sintattico**)

Classi di supporto all'analisi sintattica

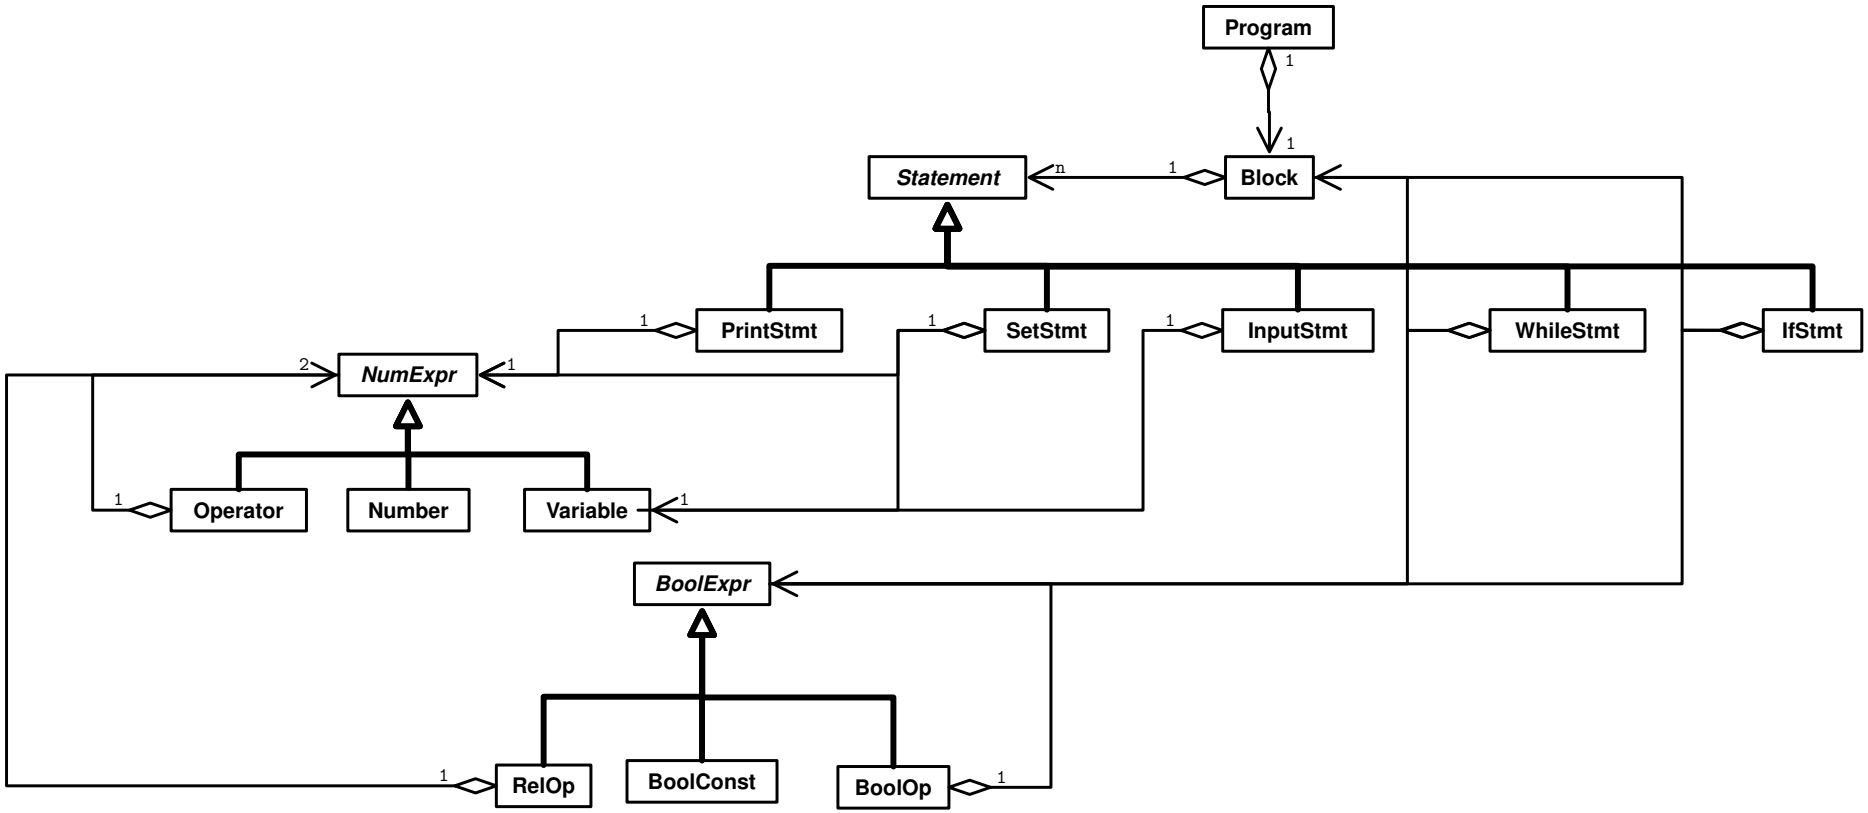

Analisi semantica

- Prende in input l'albero sintattico
- Crea una tabella dei simboli per memorizzare le variabili e i valori ad esse associati
- Crea degli opportuni registri per la valutazione delle espressioni numeriche e booleane (Suggerimento: considerare un'architettura a stack)
- Valuta l'albero sintattico (interpreta il programma) utilizzando una visita.
- Per eseguire la visita si può utilizzare un oggetto "Visitor" con opportuni metodi che consentano l'analisi dei vari elementi degli oggetti "Interpreter".

Materiale su Aulaweb

- Queste slide
- Esempi di programmi di input e relativi output
- Codice C++ di esempio per costruzione e visite di alberi

Specifiche di input/output

- L'interprete prende in input **un parametro da linea di comando** che corrisponde al nome (completo di percorso) del file contenente il programma da interpretare
- Il programma richiede eventuali input e presenta eventuali output in console

Specifiche di consegna

- Standard C++17
- Evitare estensioni specifiche di una IDE o di un sistema operativo
- Consegna dei sorgenti (header `.h` e file `.cpp`) e del diagramma UML dell'applicazione su Aulaweb (singolo file `.zip`)
- Il file `.cpp` contenente il `main` deve chiamarsi `lispInterpreter`
- Utilizzare le guardie di inclusione invece delle direttive `pragma`; ad esempio, il file `Header.h` va strutturato come:

```
#ifndef HEADER_H
#define HEADER_H


<corpo del file Header.h>


#endif
```

Valutazione

- Il progetto fornisce un punteggio massimo di 10 punti così ripartiti:
  - Correttezza sintattica 4/10: il programma compila senza errori, prende in input il file da linea di comando, genera output su console, non va in loop o in crash
  - Correttezza su test 4/10: il programma esegue correttamente i test forniti (2/10) e una serie di test ulteriori predisposti in fase di correzione (2/10)
  - Struttura e documentazione 2/10: il diagramma UML è aderente all'implementazione, il codice sorgente è organizzato e commentato chiaramente
- Il progetto è **individuale**: l'eccessiva similitudine tra diversi progetti darà luogo a penalizzazioni sul punteggio finale.